Práctica 11. Suma de matrices N x M

$$\begin{bmatrix} 2 & 6 & 5 \\ -1 & 2 & 3 \\ 0 & 1 & 5 \\ 7 & 9 & 10 \end{bmatrix}_{4\times3} + \begin{bmatrix} 2 & 5 & 7 \\ 2 & 1 & -4 \\ 5 & 6 & 8 \\ 4 & -2 & 3 \end{bmatrix}_{4\times3} = \begin{bmatrix} 4 & 11 & 12 \\ 1 & 3 & -1 \\ 5 & 7 & 13 \\ 11 & 7 & 13 \end{bmatrix}_{4\times3}$$

U.A.Q. Fac. de Informática

Dra. Sandra Luz Canchola Magdaleno

Correo: sandra.canchola@uaq.mx

Dra. Reyna Moreno Beltrán

Correo: reyna.moreno@uaq.mx



Sean A y B matrices de dimensiones n x m, la suma está definida como:

$$(A + B)_{i,j} = a_{i,j} + b_{i,j}$$

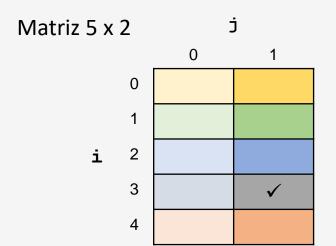
$$A_{n \times m} + B_{n \times m} = \begin{bmatrix} a_{11} + b_{11} & a_{12} + b_{12} & \dots & a_{1m} + b_{1m} \\ a_{21} + b_{21} & a_{22} + b_{22} & \dots & a_{2m} + b_{2m} \\ \dots & \dots & \dots & \dots \\ a_{n1} + b_{n1} & a_{n2} + b_{n2} & \dots & a_{nm} + b_{nm} \end{bmatrix}$$

Cálculo de suma de matrices n x m

A+B

	0	1	2	 m-1
0				
1				
2				
n-1				

Elementos de matrices



Índice de elementos

matriz[i][j]

Ejemplo:
mat1[3][1]

Matriz 5 x 2 como apuntador a una memoria consecutiva de 10 elementos



Índice de elementos

Ejemplo:

Elementos de matrices

Matriz 5 x 2 x 4

					_	j			
			()				1	
		k= 0	1	2	3	0	1	2	3
	0								
		0	1	2	3	0	1	2	3
	1							✓	
i		0	1	2	3	0	1	2	3
	2								
		0	1	2	3	0	1	2	3
	3								
		0	1	2	3	0	1	2	3
	4								

Índice de elementos

matriz[i][j][k]

Ejemplo: mat2[1][1][2]

Elementos de matrices

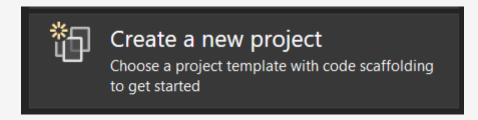
Matriz 5 x 2 x 4 como apuntador a una memoria consecutiva de 40 elementos

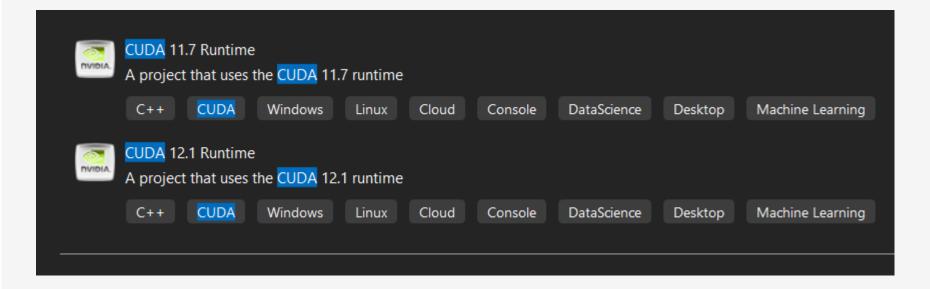
0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15		36	37	38	39
														✓		•••				

Índice de elementos

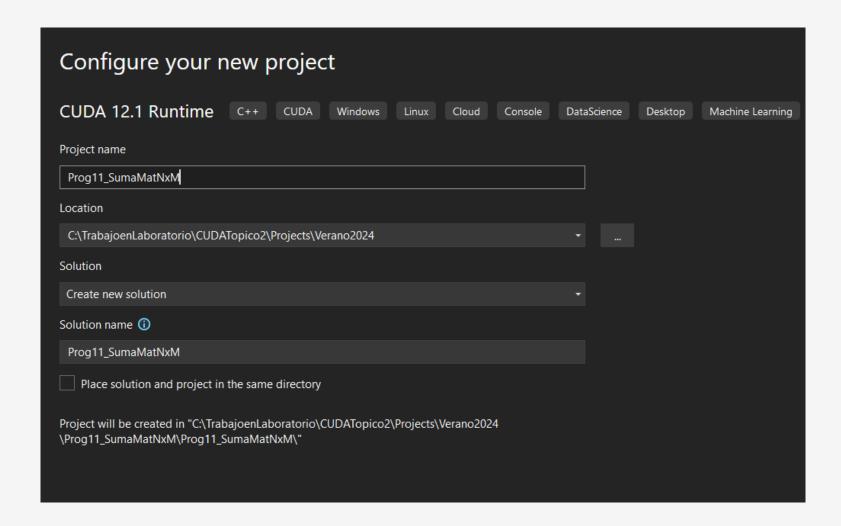
```
indice=(i*numCol*numProf)+(j*numProf)+k
Ejemplo:
mat2[1][1][2]
indice=(1*2*4)+(1*4)+2=14
```

Proyecto CUDA





Proyecto CUDA





Operaciones de memoria (CPU)

```
• malloc.- Reserva un bloque de memoria de un tamaño definido de bytes,
retornando un apuntador al inicio de dicho bloque. El contenido de dicho bloque
no se inicializa por lo que es indeterminado. Ejemplo:
       void* malloc (size t size);
       buffer = (char*) malloc (sizeof(char)*100);
• memset. - asigna valores en secciones de memoria. Ejemplo:
       Memset (variable, valor a asignar, tamaño de memoria)
       Donde: tamaño de memoria se define como n * sizeof(tipo)
• memcpy. - Copia el contenido de un bloque de memoria referenciado por un
apuntador a otro apuntador. Ejemplo:
       void* memcpy( void* dest, const void* src, std::size t count );
       memcpy (ptrDest, ptrOrigen, sizeof(int)*100);
• free. - Liberar la memoria reservada con el comando malloc. Ejemplo:
       free(pointerName);
       free (array2);
```

Operaciones de memoria (GPU)

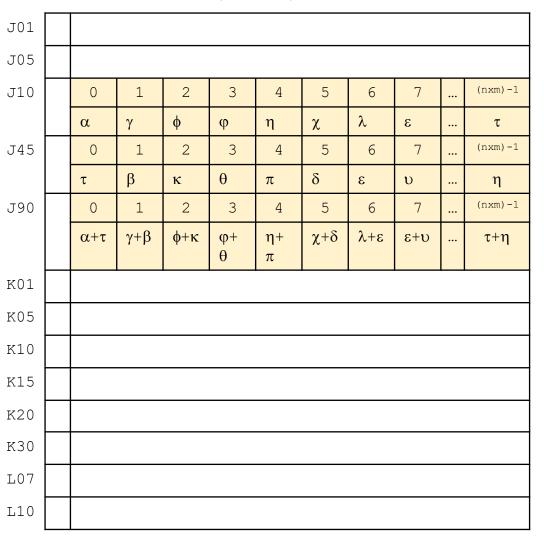
• cudaMalloc. - asigna una sección de memoria en GPU de acuerdo con el espacio solicitado. Ejemplo: cudaMalloc((void**) & apuntador, tamaño de memoria) Donde: tamaño de memoria se define como n * sizeof(tipo) • cudaMemset. - asigna valores en secciones de memoria. Ejemplo: Memset (apuntador, valor a asignar, tamaño de memoria) Donde: tamaño de memoria se define como n * sizeof(tipo) • cudaMemcpy. - copia memoria hacia y desde el device. Ejemplo: cudaMemcpy(destino, origen, tamaño de memoria, indicador flujo de inf) Donde Indicador = cudaMemcpyHostToDevice, cudaMemcpyDeviceToHost, cudaMemcpyDeviceToDevice • cudaFree.-libera la memoria reservada por un apuntador. Ejemplo: cudaFree (apuntador)

Memoria

CPU (Host)

A01	widthN	50									
A03	widthM	60									
A05	epsilon	0.0	0000	1							
A07	maxN	16									
A10	maxM	20									
A15	А	0	1	2	3	4	5	6	7		(nxm)-1
		α	γ	ф	φ	η	χ	λ	3		τ
в02	В	0	1	2	3	4	5	6	7		(nxm) -1
		τ	β	κ	θ	π	δ	3	υ		η
В45	С	0	1	2	3	4	5	6	7		(nxm)-1
		α +τ	$^{\gamma+}_{eta}$	φ+ κ	φ +θ	η +π	χ+ δ	λ+ ε	ε+ υ		τ+η
C30	C_host	0	1	2	3	4	5	6	7		(nxm)-1
		α +τ	γ+ β	φ+ κ	φ +θ	η +π	χ+ δ	λ+ ε	ε+ υ	::	τ+η
E10	dev_A	J10									
F20	dev_B	J45									
G05	dev_C	J90									
Н16											
Н20											

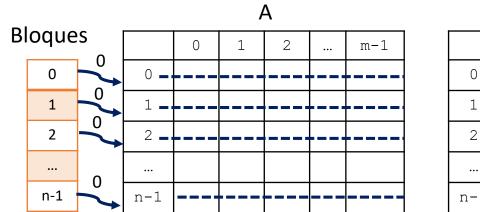
GPU (Device)

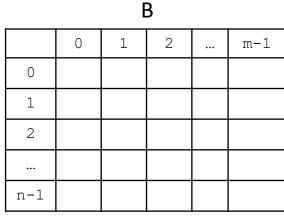


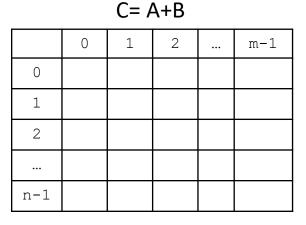
Memoria reservada

Apuntador

Caso 1. N bloques con hilo único. Cada hilo calcula el resultado de una fila completa.





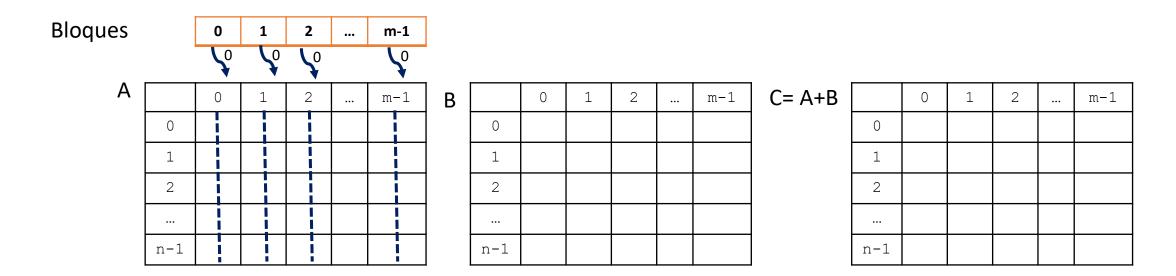


tid=blockIdx.x primerElem=(blockIdx.x*n)

blockIdx.x	threadIdx.x	tid	Ele	ementos atendidos
0	0	0	$C_{0,0}, C_{0,1}, C_{0,2} \dots C_{0,m-1}$	0,1,2,(m-1)
1	0	1	$C_{1,0}, C_{1,1}, C_{1,2} \dots C_{1,m-1}$	m,m+1,m+2,,2m-1
2	0	2	$C_{2,0}, C_{2,1}, C_{2,2} \dots C_{2,m-1}$	2m, 2m+1, 2m+2,, 3m-1
n-1	0	n-1	$C_{n-1,0}, C_{n-1,1}, C_{n-1,2} \dots C_{n-1,m-1}$	(n-1)m, (n-1)m+1, (n-1)m+2,, n*m-1

Caso 1. N bloques con hilo único. Cada hilo calcula el resultado de una fila completa.

Caso 2. N bloques con hilo único. Cada hilo calcula el resultado de una columna completa.



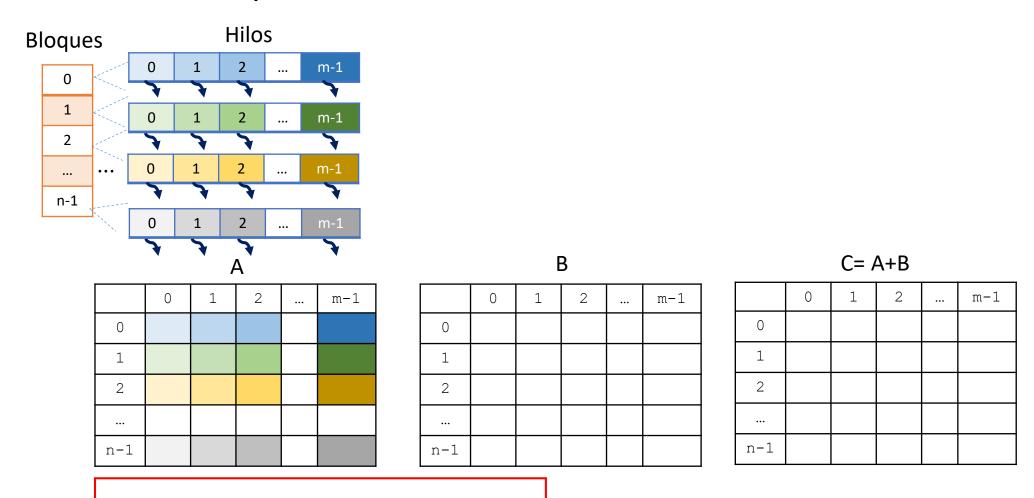
tid=blockldx.x primerElem=blockldx.x

Caso 2. N bloques con hilo único. Cada hilo calcula el resultado de una columna completa.

```
Suma de matrices tama±o
                                                                   239 x
                                                                                 240
                                  Valores maxN =
                                                          30 \text{ maxM} =
                                                                               20
                                                                 0.000 ms.
                                  Operacion en C.P.U. toma
                                  Operacion en G.P.U. toma
                                                                 1.000 ms.
#define widthN 239
                                  Configuracion de ejecucion:
                                  Grid [240, 1, 1] Bloque [1, 1, 1]
#define widthM 240
                                  Elementos diferentes 0 (0.000 %) Con valor de 0.0000000000000000000
#define epsilon float(0.000001)
                                 Presione cualquier tecla para salir...
dim3 dimGrid(widthM);
dim3 dimBlock(1);
int tid = blockIdx.x;
for (int i = 0; i < widthN; i++){
         c[tid + (i * widthM)] = a[tid + (i * widthM)] + b[tid + (i * widthM)];
```

C:\TrabajoenLaboratorio\CUD ×

Caso 3. N bloques con M hilos cada uno.



tid=(blockIdx.x*blockDim.x)+threadIdx.x

blockIdx.x	threadIdx.x	tid	Elemento	os atendidos
0	0	0	$C_{0,0}, C_{1,0}, C_{2,0} \dots C_{n-1,0}$	0,m,2m,,(n-1)m
1	0	1	$C_{0,1}, C_{1,1}, C_{2,1} \dots C_{n-1,1}$	1,m+1,2m+1,(n-1)m+1
2	0	2	$C_{0,2}, C_{1,2}, C_{2,2} \dots C_{n-1,2}$	2,m+2, 2m+2,(n-1)m+2
		•••		
n-1	0	n-1	$C_{0m-1}, C_{1,m-1}, C_{2,m-1} \dots C_{n-1,m-1}$	m-1,2m-1,(nxm)-1

Caso 3. N bloques con M hilos cada uno.

#define widthN 239

```
#define widthM 240
#define epsilon float(0.0000001)
dim3 dimGrid(widthN); // por cada renglon
dim3 dimBlock(widthM); // por cada columna
int tid = (blockIdx.x*blockDim.x)+threadIdx.x;
c[tid] = a[tid] + b[tid];
                                              © C:\TrabajoenLaboratorio\CUD ×
                                              Suma de matrices tama±o
                                                                              239 x
                                                                                           240
                                              Valores maxN =
                                                                     30 \text{ maxM} =
                                                                                         20
                                              Operacion en C.P.U. toma
                                                                             0.000 ms.
                                             Operacion en G.P.U. toma
                                                                            1.000 ms.
                                             Configuracion de ejecucion:
                                             Grid [239, 1, 1] Bloque [240, 1, 1]
                                              Elementos diferentes 0 (0.000 %) Con valor de 0.000000000000
                                             Presione cualquier tecla para salir...
```

Caso 4. Un bloque con NxM hilos

Bloque 0 Hilos 0 1 2 ... m-1

n-1

A 0 1 2 ... m-1 0 1 2 ... m-1 2 ... m-1 ...

0 1 2 ... m-1
0 1 2 ... m-1
... m-1
n-1

В

C = A + B

tid=(threadIdx.x*blockDim.y)+threadIdx.y

Caso 4. Un bloque con NxM hilos

#define widthN 32

```
#define widthM 31
#define epsilon float(0.0000001)
dim3 dimGrid(1);
dim3 dimBlock(widthN, widthM); // por cada elemento
int tid = (threadIdx.x*blockDim.y) + threadIdx.y;
c[tid] = a[tid] + b[tid];
                                       Suma de matrices tama±o
                                                                 32 x
                                                                            31
                                      Valores maxN =
                                                         30 \text{ maxM} =
                                                                         20
                                      Operacion en C.P.U. toma
                                                               0.000 ms.
                                      Operacion en G.P.U. toma
                                                               0.000 ms.
                                      Configuracion de ejecucion:
                                      Presione cualquier tecla para salir...
```

Caso 5. Bloque 2D con hilos 2D

Hilos

	0	1	2
0	7	7	7
1	*	7	7
2	7	7	7
3	*	7	7

Tamaño de la matriz 13 x 10

maxN=4, maxM=3 Cada bloque tiene maxN x maxM hilos.

Dimensión del grid

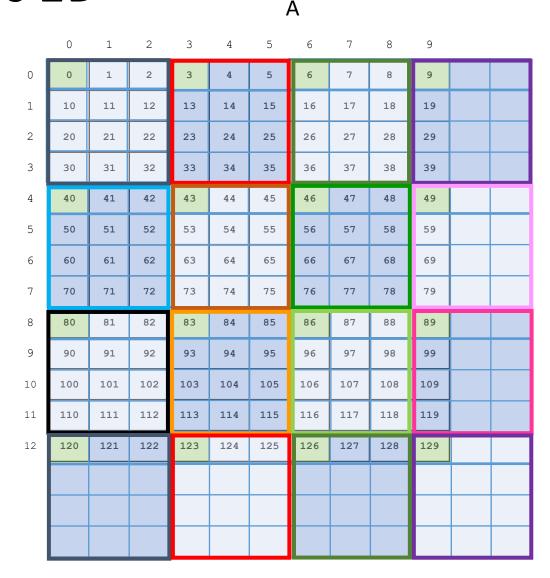
Primera dimensión N / maxN = 13 / 4 = $3.25 \approx 4$ Segunda dimensión M / maxM = $10 / 3 = 3.3333 \approx 4$

						F	4				
	0	1	2	3	4	5	6	7	8	9	
0	0	1	2	3	4	5	6	7	8	9	
1	10	11	12	13	14	15	16	17	18	19	
2	20	21	22	23	24	25	26	27	28	29	
3	30	31	32	33	34	35	36	37	38	39	
4	40	41	42	43	44	45	46	47	48	49	
5	50	51	52	53	54	55	56	57	58	59	
6	60	61	62	63	64	65	66	67	68	69	
7	70	71	72	73	74	75	76	77	78	79	
8	80	81	82	83	84	85	86	87	88	89	
9	90	91	92	93	94	95	96	97	98	99	
10	100	101	102	103	104	105	106	107	108	109	
11	110	111	112	113	114	115	116	117	118	119	
12	120	121	122	123	124	125	126	127	128	129	

Caso 5. Bloque 2D con hilos 2D

maxN=4, maxM=3 Cada bloque tiene maxN x maxM hilos.

filaInicialBloque=(blockIdx.x*blockDim.x) fila=filaInicialBloque+threadIdx.x columnaIniciaBloque=(blockIdx.y*blockDim.y) columna=columnaInicialBloque+threadIdx.y



blo	ckI x	l	ead dx	E]	ement	0	1 -	ckI x		ead dx	E	Lemento)		ckI lx		ead dx	El	ement		blo	ckI x		ead	E	emento	>
х	У	ж	У	fila	col	#	х	У	ж	У	fila	col	#	х	У	х	У	fila	col	#	х	У	ж	У	fila	col	#
0	0	0	0	0	0	0	0	2	0	0	0	6	6	1	0	0	0	4	0	40	1	2	0	0	4	6	46
0	0	0	1	0	1	1	0	2	0	1	0	7	7	1	0	0	1	4	1	41	1	2	0	1	4	7	47
0	0	0	2	0	2	2	0	2	0	2	0	8	8	1	0	0	2	4	2	42	1	2	0	2	4	8	48
0	0	1	0	1	0	10	0	2	1	0	1	6	16	1	0	1	0	5	0	50	1	2	1	0	5	6	56
0	0	1	1	1	1	11	0	2	1	1	1	7	17	1	0	1	1	5	1	51	1	2	1	1	5	7	57
0	0	1	2	1	2	12	0	2	1	2	1	8	18	1	0	1	2	5	2	52	1	2	1	2	5	8	58
0	0	2	0	2	0	20	0	2	2	0	2	6	26	1	0	2	0	6	0	60	1	2	2	0	6	6	66
0	0	2	1	2	1	21	0	2	2	1	2	7	27	1	0	2	1	6	1	61	1	2	2	1	6	7	67
0	0	2	2	2	2	22	0	2	2	2	2	8	28	1	0	2	2	6	2	62	1	2	2	2	6	8	68
0	0	3	0	3	0	30	0	2	3	0	3	6	36	1	0	3	0	7	0	70	1	2	3	0	7	6	76
0	0	3	1	3	1	31	0	2	3	1	3	7	37	1	0	3	1	7	1	71	1	2	3	1	7	7	77
0	0	3	2	3	2	32	0	2	3	2	3	8	38	1	0	3	2	7	2	72	1	2	3	2	7	8	78
0	1	0	0	0	3	3	0	3	0	0	0	9	9	1	1	0	0	4	3	43	1	3	0	0	4	9	49
0	1	0	1	0	4	4	0	3	0	1	0	10	10	1	1	0	1	4	4	44	1	3	0	1	4	10	50
0	1	0	2	0	5	5	0	3	0	2	0	11	11	1	1	0	2	4	5	45	1	3	0	2	4	11	51
0	1	1	0	1	3	13	0	3	1	0	1	9	19	1	1	1	0	5	3	53	1	3	1	0	5	9	59
0	1	1	1	1	4	14	0	3	1	1	1	10	20	1	1	1	1	5	4	54	1	3	1	1	5	10	60
0	1	1	2	1	5	15	0	3	1	2	1	11	21	1	1	1	2	5	5	55	1	3	1	2	5	11	61
0	1	2	0	2	3	23	0	3	2	0	2	9	29	1	1	2	0	6	3	63	1	3	2	0	6	9	69
0	1	2	1	2	4	24	0	3	2	1	2	10	30	1	1	2	1	6	4	64	1	3	2	1	6	10	70
0	1	2	2	2	5	25	0	3	2	2	2	11	31	1	1	2	2	6	5	65	1	3	2	2	6	11	71
0	1	3	0	3	3	33	0	3	3	0	3	9	39	1	1	3	0	7	3	73	1	3	3	0	7	9	79
0	1	3	1	3	4	34	0	3	3	1	3	10	40	1	1	3	1	7	4	74	1	3	3	1	7	10	80
0	1	3	2	3	5	35	0	3	3	2	3	11	41	1	1	3	2	7	5	75	1	3	3	2	7	11	81

blo	ckI x	l	ead dx	El	ement	0		ckI lx		ead dx	E	Lemento	0		ckI lx	_	ead dx	El	ement	o	blockI dx		thread Idx		E]	ement	>
х	У	ж	У	fila	col	#	х	У	ж	У	fila	col	#	х	У	ж	У	fila	col	#	х	У	ж	У	fila	col	#
2	0	0	0	8	0	80	2	2	0	0	8	6	86	3	0	0	0	12	0	120	3	2	0	0	12	6	126
2	0	0	1	8	1	81	2	2	0	1	8	7	87	2	0	0	1	12	1	121	2	2	0	1	12	7	127
2	0	0	2	8	2	82	2	2	0	2	8	8	88	2	0	0	2	12	2	122	2	2	0	2	12	8	128
2	0	1	0	9	0	90	2	2	1	0	9	6	96	2	0	1	0	13	0	130	2	2	1	0	13	6	136
2	0	1	1	9	1	91	2	2	1	1	9	7	97	2	0	1	1	13	1	131	2	2	1	1	13	7	137
2	0	1	2	9	2	92	2	2	1	2	9	8	98	2	0	1	2	13	2	132	2	2	1	2	13	8	138
2	0	2	0	10	0	100	2	2	2	0	10	6	106	2	0	2	0	14	0	140	2	2	2	0	14	6	146
2	0	2	1	10	1	101	2	2	2	1	10	7	107	2	0	2	1	14	1	141	2	2	2	1	14	7	147
2	0	2	2	10	2	102	2	2	2	2	10	8	108	2	0	2	2	14	2	142	2	2	2	2	14	8	148
2	0	3	0	11	0	110	2	2	3	0	11	6	116	2	0	3	0	15	0	150	2	2	3	0	15	6	156
2	0	3	1	11	1	111	2	2	3	1	11	7	117	2	0	3	1	15	1	151	2	2	3	1	15	7	157
2	0	3	2	11	2	112	2	2	3	2	11	8	118	2	0	3	2	15	2	152	2	2	3	2	15	8	158
2	1	0	0	8	3	83	2	3	0	0	8	9	89	3	1	0	0	12	3	123	3	3	0	0	12	9	129
2	1	0	1	8	4	84	2	3	0	1	8	10	90	2	1	0	1	12	4	124	2	3	0	1	12	10	130
2	1	0	2	8	5	85	2	3	0	2	8	11	91	2	1	0	2	12	5	125	2	3	0	2	12	11	131
2	1	1	0	9	3	93	2	3	1	0	9	9	99	2	1	1	0	13	3	133	2	3	1	0	13	9	139
2	1	1	1	9	4	94	2	3	1	1	9	10	100	2	1	1	1	13	4	134	2	3	1	1	13	10	140
2	1	1	2	9	5	95	2	3	1	2	9	11	101	2	1	1	2	13	5	135	2	3	1	2	13	11	141
2	1	2	0	10	3	103	2	3	2	0	10	9	109	2	1	2	0	14	3	143	2	3	2	0	14	9	149
2	1	2	1	10	4	104	2	3	2	1	10	10	110	2	1	2	1	14	4	144	2	3	2	1	14	10	150
2	1	2	2	10	5	105	2	3	2	2	10	11	111	2	1	2	2	14	5	145	2	3	2	2	14	11	151
2	1	3	0	11	3	113	2	3	3	0	11	9	119	2	1	3	0	15	3	153	2	3	3	0	15	9	159
2	1	3	1	11	4	114	2	3	3	1	11	10	120	2	1	3	1	15	4	154	2	3	3	1	15	10	160
2	1	3	2	11	5	115	2	3	3	2	11	11	121	2	1	3	2	15	5	155	2	3	3	2	15	11	161

Caso 5. Bloque 2D con hilos 2D

```
#define widthN 239
#define widthM 240
#define epsilon float(0.0000001)
#define maxN 30
#define maxM 20
int numBloquesN = divEntera(widthN , maxN);
int numBloquesM = divEntera(widthM , maxM);
dim3 dimGrid(numBloquesN, numBloquesM);
dim3 dimBlock(maxN, maxM);
int fila = (blockIdx.x * blockDim.x) + threadIdx.x;
int columna = (blockIdx.y * blockDim.y) + threadIdx.y;
if ((fila < widthN) && (columna < widthM)) {
         int tid = (fila * widthM) + columna;
         c[tid] = a[tid] + b[tid];
```

Bibliografía

- Documentación CUDA C++ Programming Guide NVIDIA. 2024 https://docs.nvidia.com/cuda/cuda-c-programming-guide/index.html
- Sitio CUDA Toolkit Documentation NVIDIA, 2024. https://docs.nvidia.com/cuda/index.html
- Storti, Duane; Yurtoglu, Mete. **CUDA for Engineers:An Introduction to High-Performance Parallel Computing**. Addisson Wesley. 2015.
- Cheng, John; Grossman, Max; McKercher. Professional CUDA C Programming. Edit. Wrox. 2014.
- Sanders, Jason; Kandrot, Edward. **CUDA by Example:An Introduction to General-Purpose GPU Programming**. Addisson Wesley. 2011.
- Kirk, David; Hwu, Wen-mei. Programming Massively Parallel Processors: A Hands-on Approach. Elsevier. 2010.

Gracias por su atención

U.A.Q. Fac. de Informática Campus Juriquilla

Dra. Sandra Luz Canchola Magdaleno sandra.canchola@uaq.mx Cel. 442-1369270

Dra. Reyna Moreno Beltrán reyna.moreno@uaq.mx

DRA. + Sandra Luz
CANCHOLA
MAGDALENO